savindmitrij29@gmail.com

1. Модель работает, переобучения нет

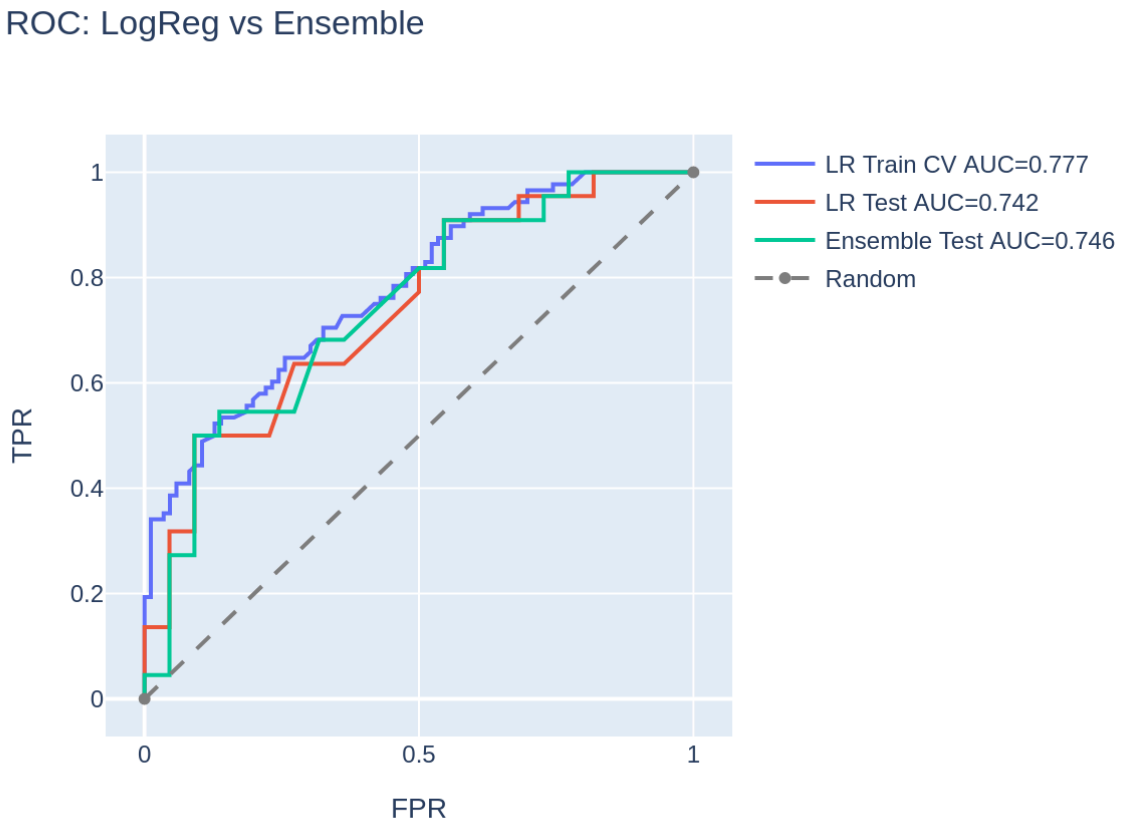

AUC на трейне 0,777, на тесте 0,742 – разница всего 0,035. Это отличный результат: модель не заучила тренировочные данные, а выучила реальные паттерны. Ансамбль на тесте 0,746 – почти идентично логрегу, значит зависимость линейная и логрег здесь вполне достаточен.

Вывод для презентации: цитирование в нейроответах предсказуемо на ~74%, это не случайность – есть конкретные факторы, на которые можно влиять.

---

2. Что повышает шанс цитирования

Топ-20 коэффициентов

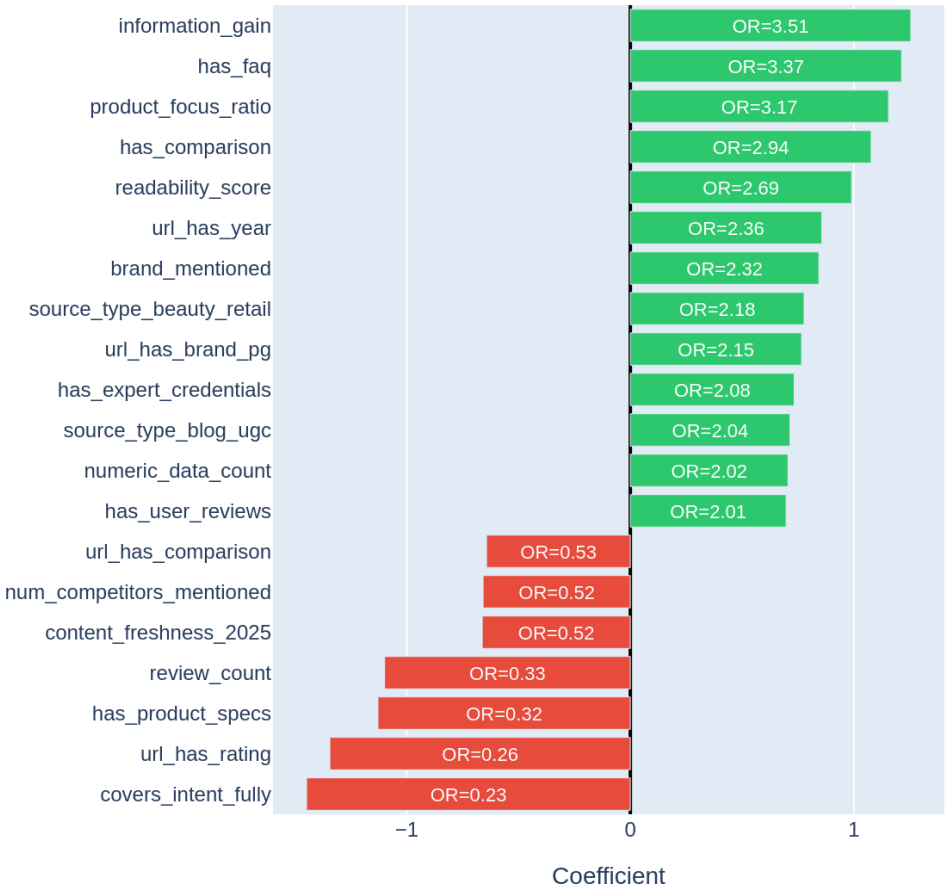

Три главных фактора:

information_gain (OR = 3.51) — уникальность контента. Страницы с информацией, которой нет у других, цитируются в 3.5 раза чаще. Это самый сильный сигнал. Рекомендация: создавать контент с собственными тестами, исследованиями, данными — то, что нельзя найти на десяти других сайтах.

has_faq (OR = 3.37) — наличие FAQ-блока. Нейросеть любит структурированные ответы на вопросы, потому что ей проще извлекать из них информацию. Рекомендация: добавлять FAQ на все ключевые страницы товаров P&G.

product_focus_ratio (OR = 3.17) — доля текста, посвящённая продукту. Страницы, где 70% контента про товар, цитируются втрое чаще, чем размытые обзоры обо всём. Рекомендация: не разбавлять страницы нерелевантным контентом.

Далее по силе: **has_comparison** (OR = 2.94) — сравнения с конкурентами, **readability_score** (OR = 2.69) — читаемость текста, **brand_mentioned** (OR = 2.32) — упоминание бренда P&G.

3. Что снижает шанс цитирования — контринтуитивные находки

covers_intent_fully (OR = 0.23) – страницы, «полностью покрывающие запрос», цитируются реже. Это парадокс, но, вероятно, нейросеть предпочитает компактные точные ответы, а не длинные «энциклопедические» страницы. Она берёт кусочки из нескольких источников, а не один большой.

has_product_specs (OR = 0.32) – сухие технические характеристики без контекста не цитируются. Нейросети нужна интерпретация, а не просто таблица параметров.

url_has_rating (OR = 0.26) – страницы-рейтинги (типичные «ТОП-10 лучших...») цитируются реже. Вероятно, нейросеть считает их менее авторитетными.

review_count (OR = 0.33) — большое количество отзывов само по себе не помогает. Нейросети важнее качество контента, а не объём пользовательских мнений.

4. Модель работает по-разному для разных типов запросов

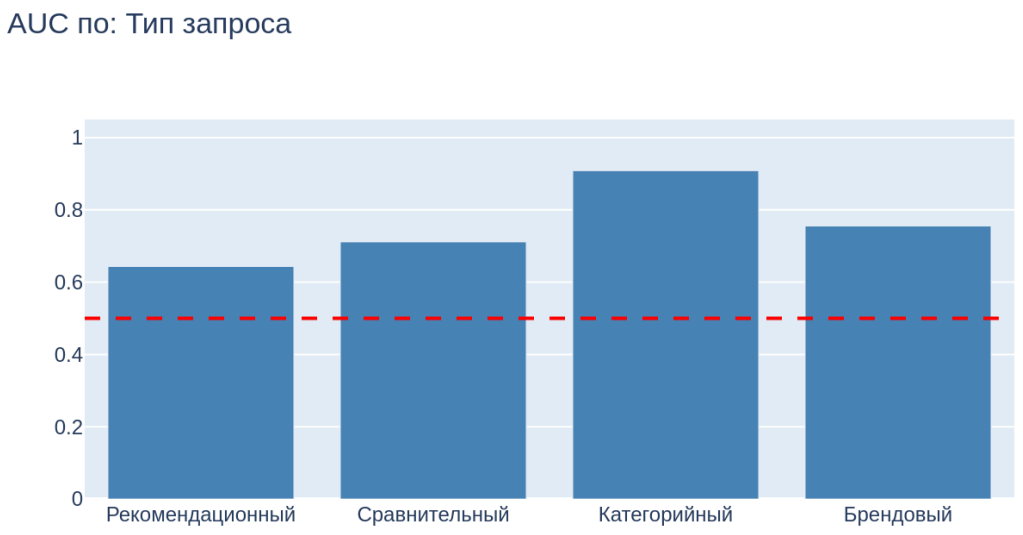

Категорийные запросы («лучшая зубная щётка 2025») — AUC = 0.90. Модель отлично предсказывает, что будет цитироваться. Здесь факторы понятны и стабильны.

Брендовые запросы («Oral-B отзывы») — AUC = 0.75. Хорошо, но слабее. Для брендовых запросов нейросеть может иметь свои предпочтения по площадкам.

Рекомендационные запросы («какую зубную пасту выбрать для ребёнка») — AUC = 0.64. Здесь модель слабее всего. Рекомендация: для рекомендационных запросов нужна отдельная контентная стратегия, текущие факторы работают хуже.

---

5. Категория Baby Care предсказывается лучше всего

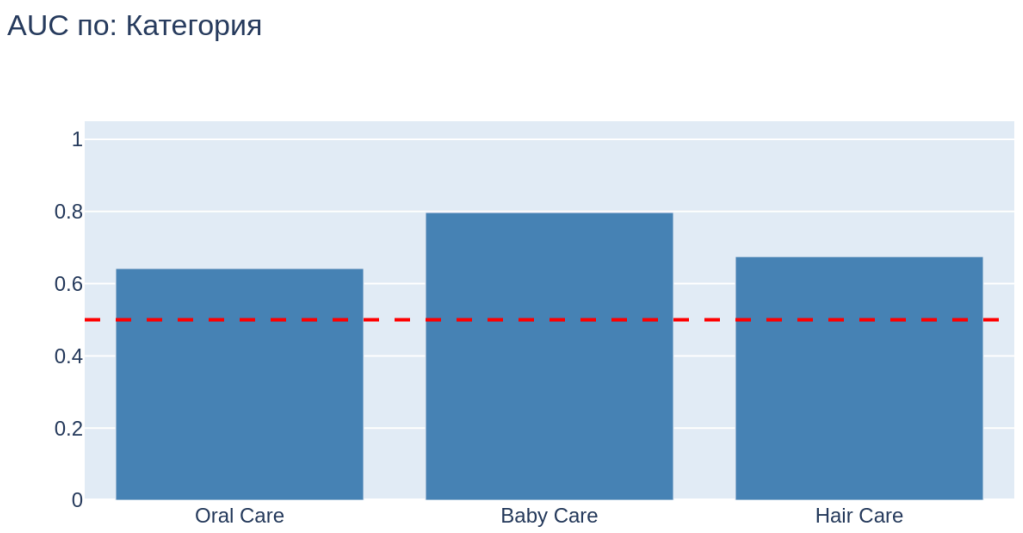

Baby Care (AUC ≈ 0.79) заметно впереди Oral Care (0.64) и Hair Care (0.67). Это значит, что для подгузников Pampers факторы цитирования наиболее устойчивы. Для Oral Care и Hair Care либо нужно больше данных, либо нейросеть использует там другие критерии отбора.

---

6. LogReg vs Ensemble — выводы устойчивы

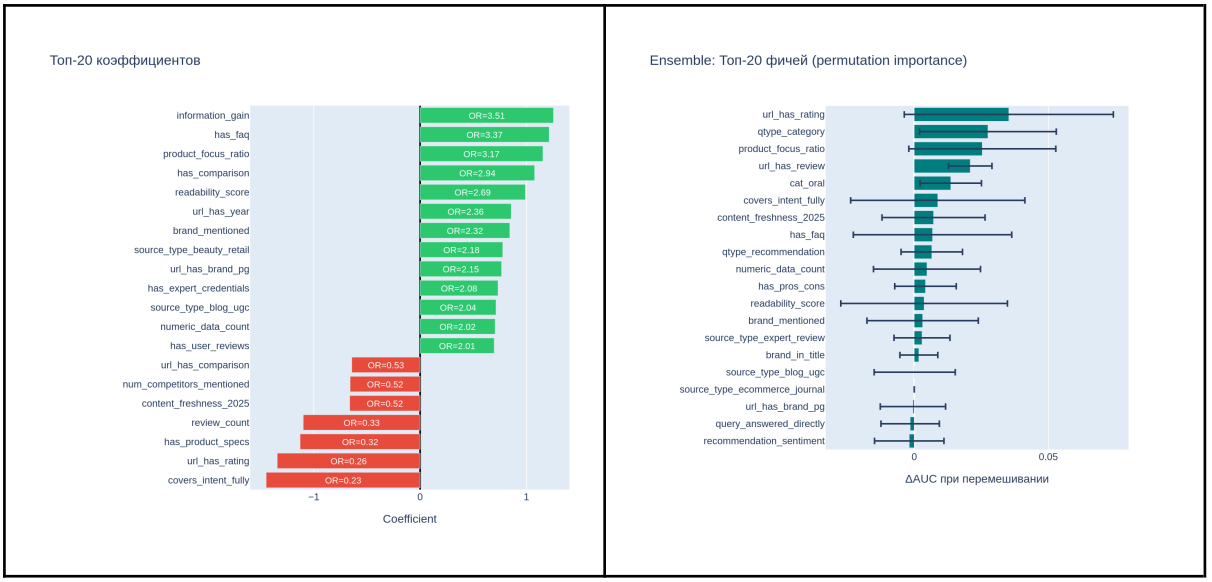

Фичи, попавшие в топ обеих моделей: **product_focus_ratio**, **has_faq**, **readability_score**, **brand_mentioned**, **numeric_data_count**. Это самые надёжные рекомендации – они подтверждены и линейной моделью, и нелинейным ансамблем.

Интересные расхождения: ансамбль ставит **url_has_rating** на первое место, а логрег — на предпоследнее. Это значит, что связь нелинейная: рейтинговые страницы в целом цитируются реже, но на определённых типах запросов — чаще. Ансамбль улавливает это взаимодействие.

---

7. Порог классификации

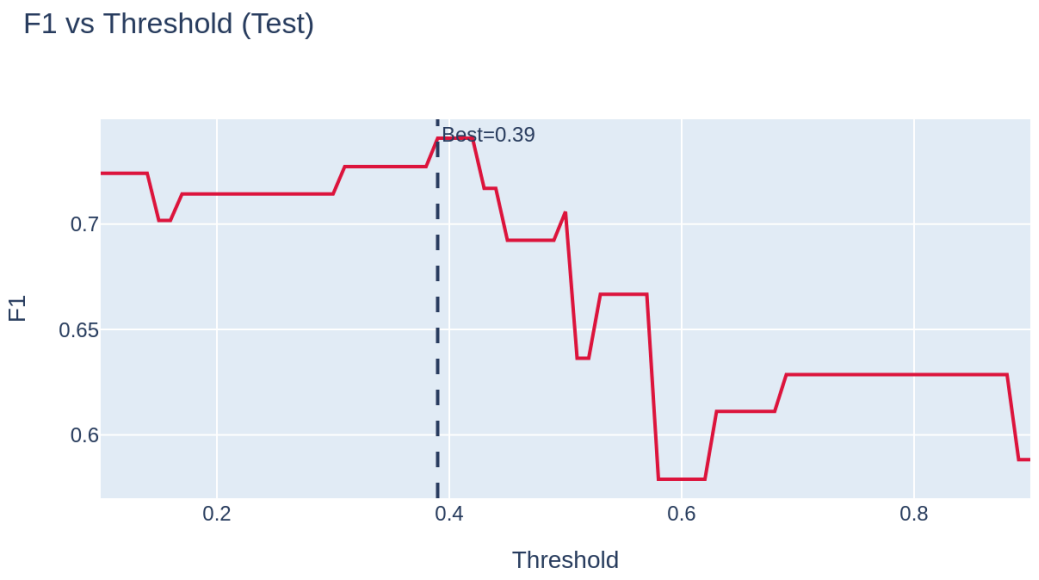

Оптимальный порог 0.39, а не стандартный 0.50. Модель склонна занижать вероятности, поэтому при пороге 0.39 баланс precision/recall лучше. На практике это означает: если модель даёт источнику вероятность цитирования 0.40 – его стоит считать потенциально цитируемым.

Итоговые рекомендации для P&G

Усилить (подтверждено обеими моделями):

1. Уникальный контент — собственные тесты, исследования, эксклюзивные данные
2. FAQ-блоки на всех ключевых страницах
3. Фокус страницы на продукте (не размывать контент)
4. Прямые сравнения с конкурентами
5. Читаемость и структура текста
6. Упоминание бренда в контексте рекомендаций

Избегать:

1. Длинных «энциклопедических» страниц – лучше компактные и точные
2. Сухих спецификаций без пояснений
3. Ставки только на количество отзывов без качественного контента

Дифференцировать стратегию:

1. Для категорийных запросов – текущая стратегия работает хорошо
2. Для рекомендательных запросов – нужен отдельный подход, текущие факторы недостаточны

3. Baby Care – модель наиболее уверена, масштабировать подход на другие категории